DTCC

2016中国数据库技术大会

DATABASE TECHNOLOGY CONFERENCE CHINA 2016

数 据 定 义 未 来

SequeMedia 盛拓传媒　IT168.com　ChinaUnix　ITPUB

Baidu Districted Redis Platform

百度分布式Redis平台

百度DBA架构师　张东阳

自我介绍

- 张东阳 2010年硕士毕业于中科院计算所
- 百度Redis方向技术负责人
- 专注于底层技术（FS 、CACHE、Linux kernel）

大纲

- BDRP在百度的应用
- 架构介绍
- 挑战与解决方案
- 总结

大纲

- BDRP在百度的应用
- 架构介绍
- 挑战与解决方案
- 总结

BDRP在百度的应用

Redis 实例 5w+，服务数2k+，物理机5k台+

典型业务

- 凤巢（商户物料信息）
- 诚信（首页加V信息）
- 糯米（促销信息）
- 度秘（用户聊天信息）
- 百度钱包（红包库存信息）

大纲

- BDRP在百度的应用
- 架构介绍
- 挑战与解决方案
- 总结

系统框架

对外接口	名字服务	客户端	Dash Board
基础组件	Proxy	Redis	元数据管理
集群管理	上线部署	容量管理	集群信息管理
	权限管理	版本管理/升级	
虚拟化	Container	Container	Container

数据流图

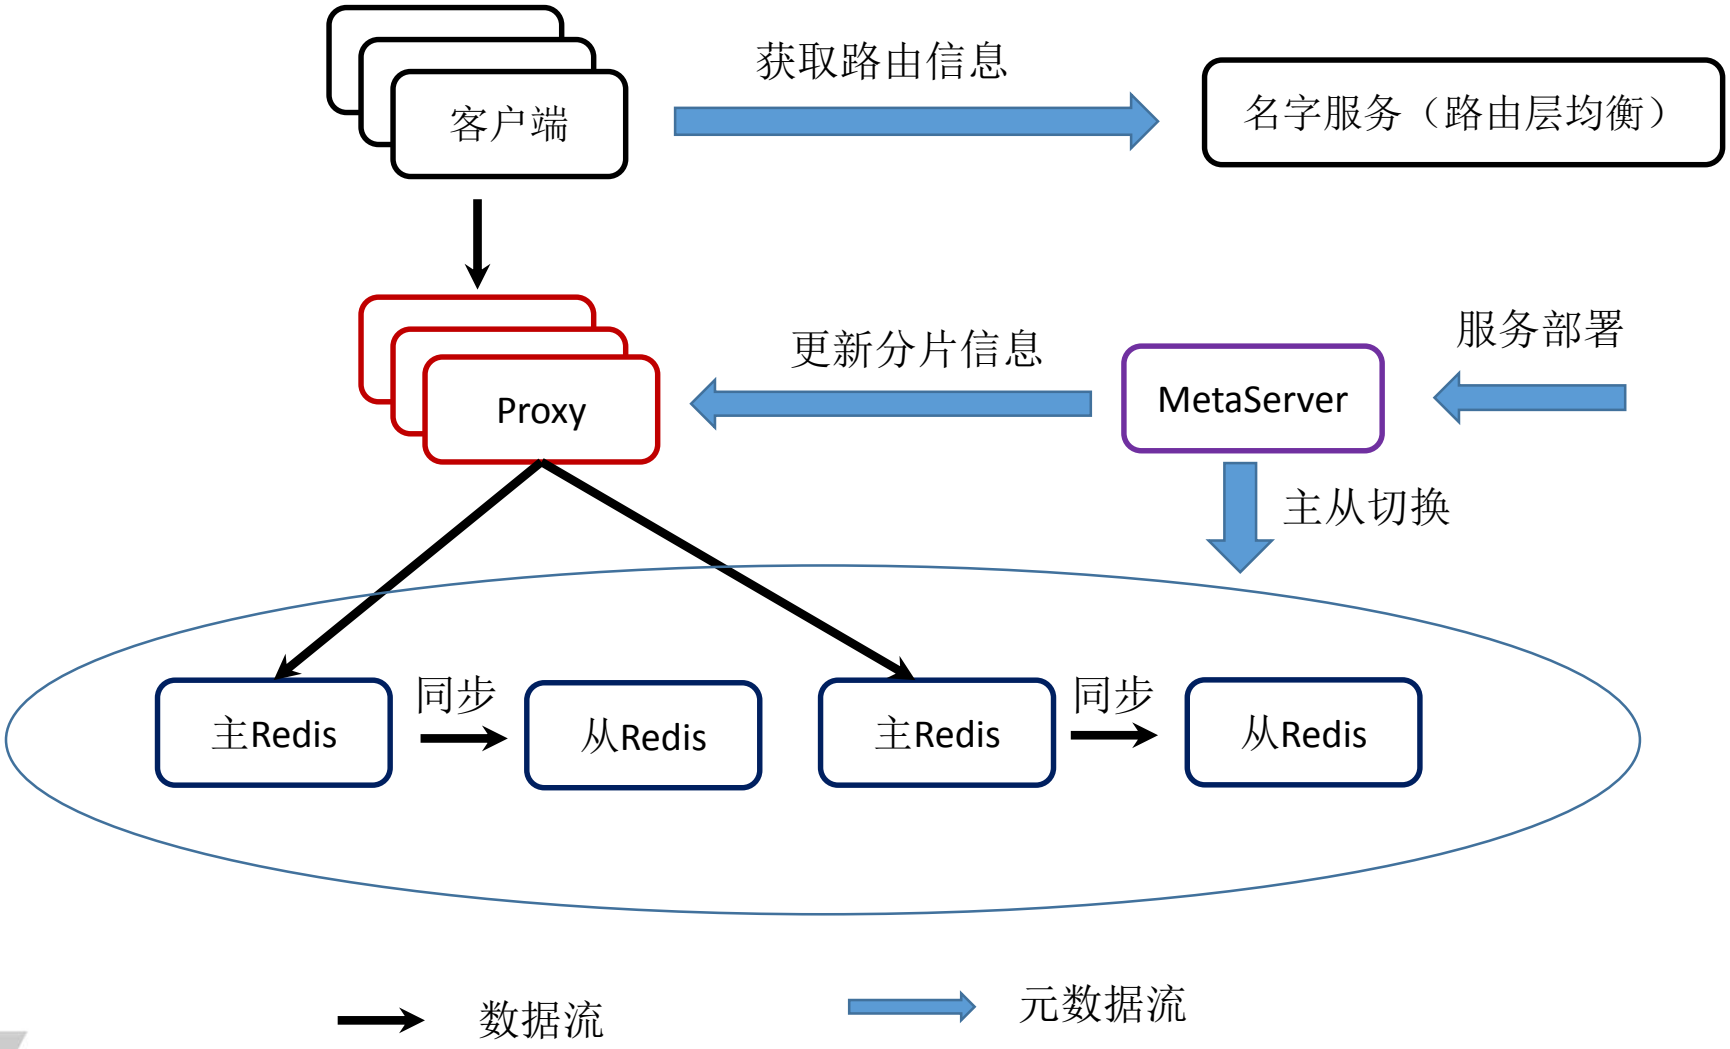
客户端
获取路由信息
名字服务（路由层均衡）
Proxy
更新分片信息
MetaServer
服务部署
主从切换
主Redis
同步
从Redis
主Redis
同步
从Redis
数据流
元数据流

大纲

- BDRP在百度的应用
- 架构介绍
- 挑战与解决方案
- 总结

挑战-以糯米为例

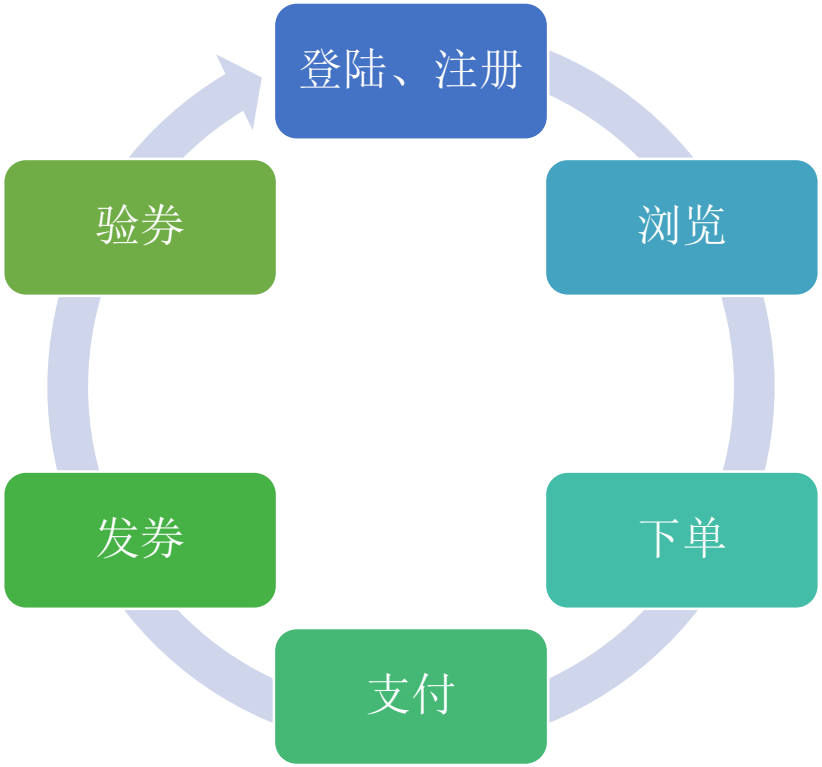

- 全交易闭环重度依赖，如登录90%以上流量由Redis承担
  - 可用性（机器、机房）
- 访问量巨大，大促时促销服务一天访问量数千亿
  - 性能（时延、吞吐）
  - 扩展性
- 存储（MySQL、Redis）资源使用巨大，数千台物理机
  - 存储使用配比

挑战-性能

- 近地域多机房（十几ms网络时延）
  - 一次业务访问几十次读取Redis（读时延放大）
  - 读写比高（ > 100：1）
  - 读吞吐高（单集群数百万QPS）

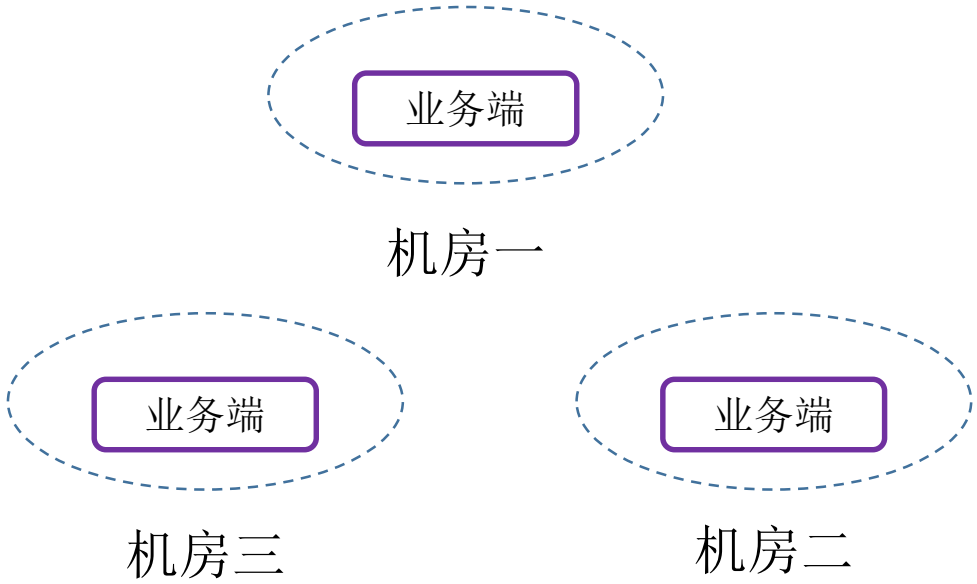

近地域多机房方案

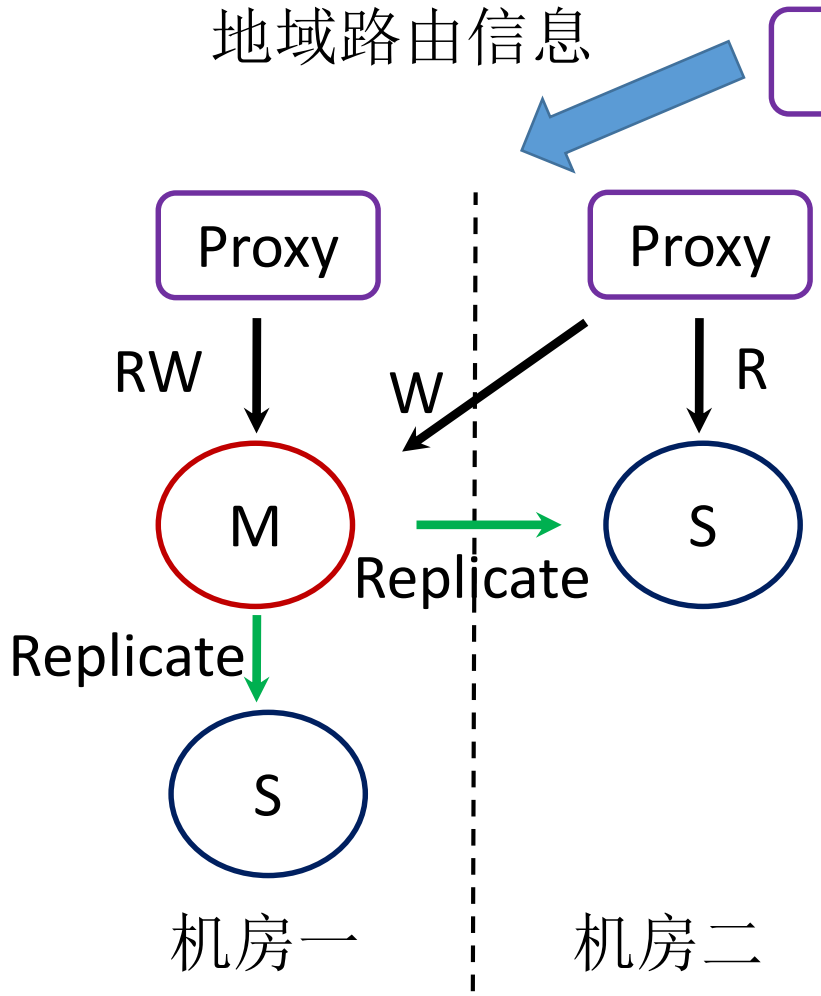

- Proxy读写分离
- MetaServer传播地域路由信息

挑战-可用性

- 社区版切主时从库向新主全量同步
  - 主库网卡压力陡增 –服务不可写
  - 从库同步时间几十分钟-服务不可读

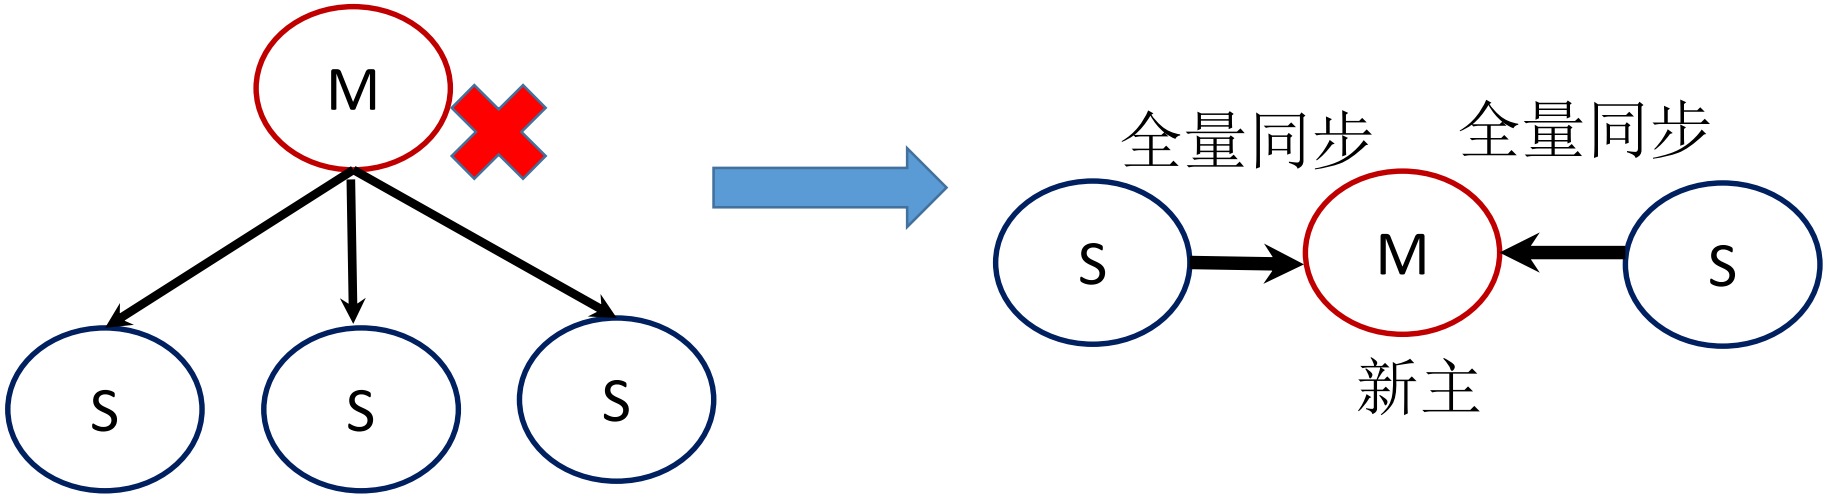

机器故障秒级切主

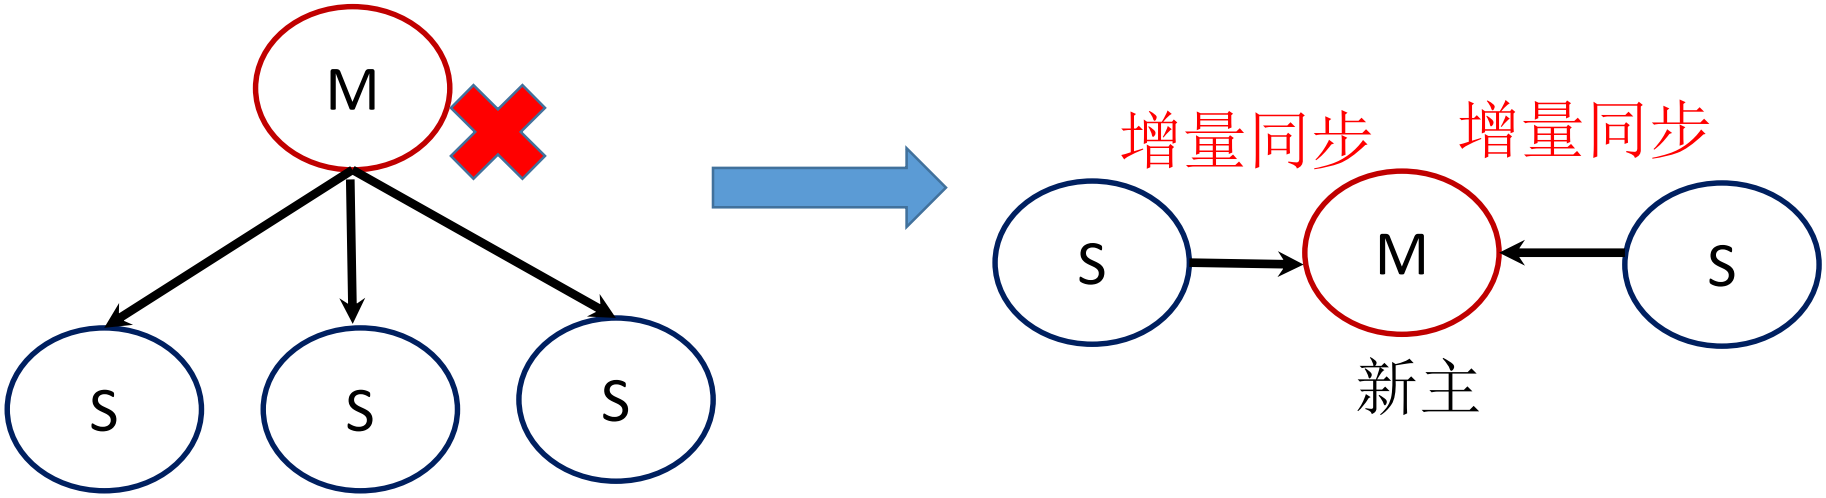

- 同源增量同步
  - 网卡压力**突增->平稳**
  - 10G内存同步时间**10min->5s**

1分钟整机房切换

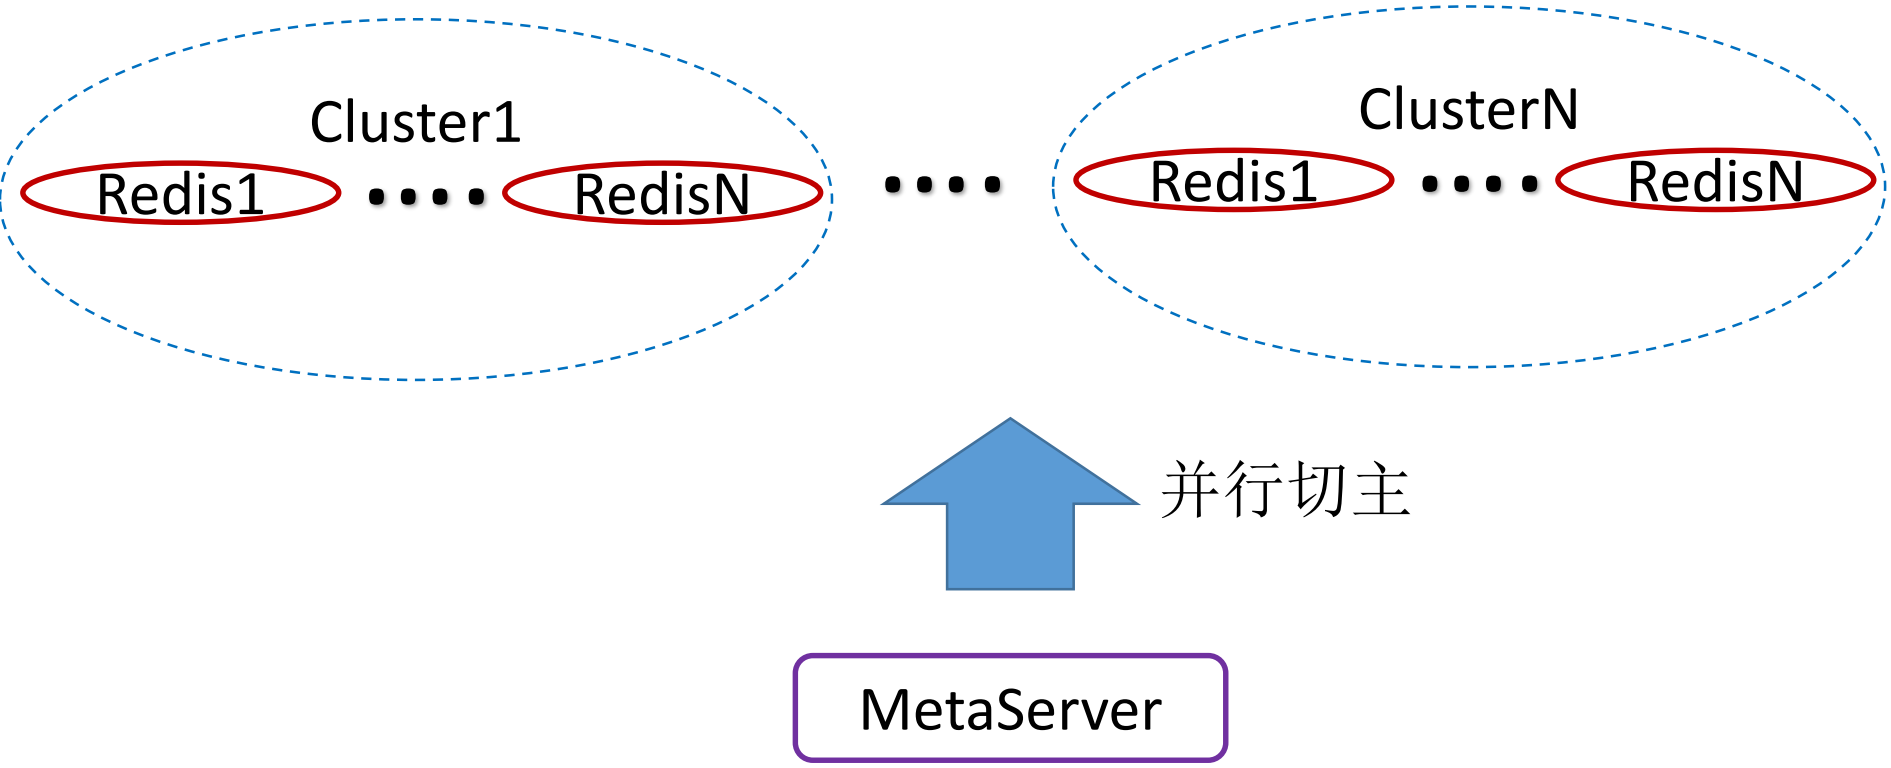
Cluster1
Redis1
RedisN
ClusterN
Redis1
RedisN
并行切主
MetaServer

挑战-扩展性

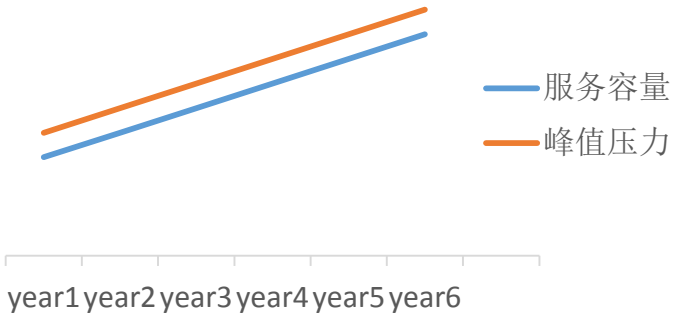

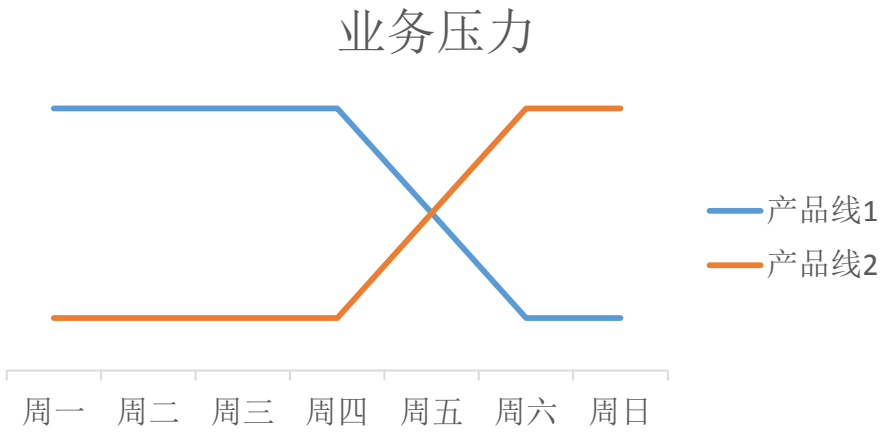

大促压力高于服务容量，频繁扩缩容-> 弹性扩缩容
不同业务不同时间段压力不同->服务混部

扩展性-redis V2.x 方案

- 成倍扩容（2->4）

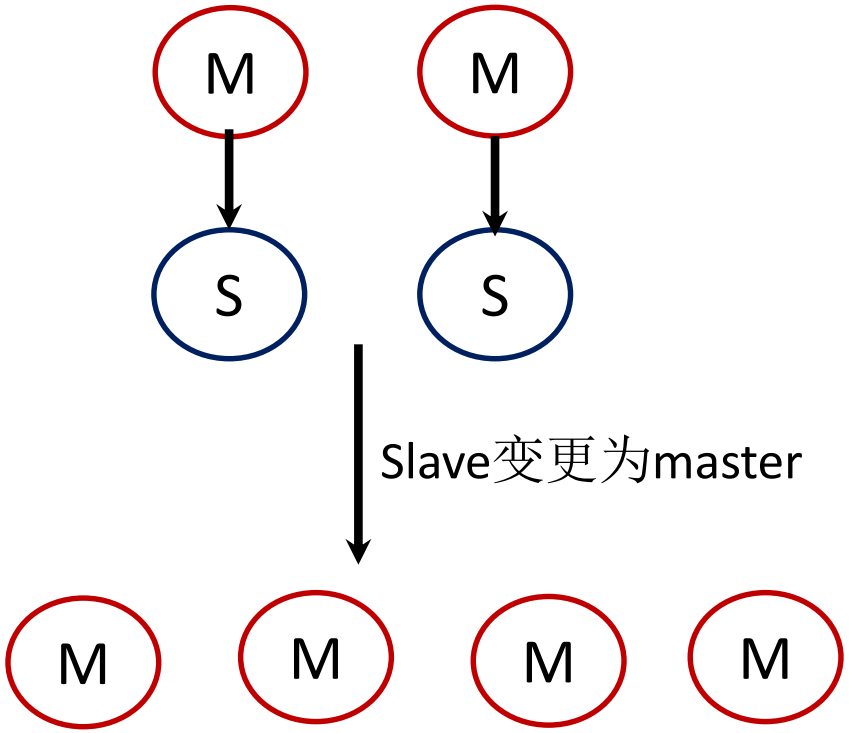

- 服务迁移（2->3）

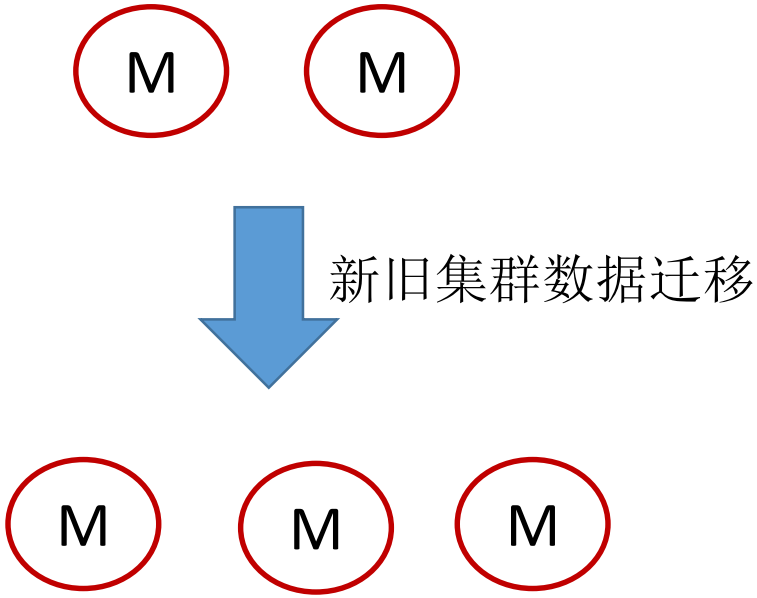

弹性扩缩容-Redis Cluster方案

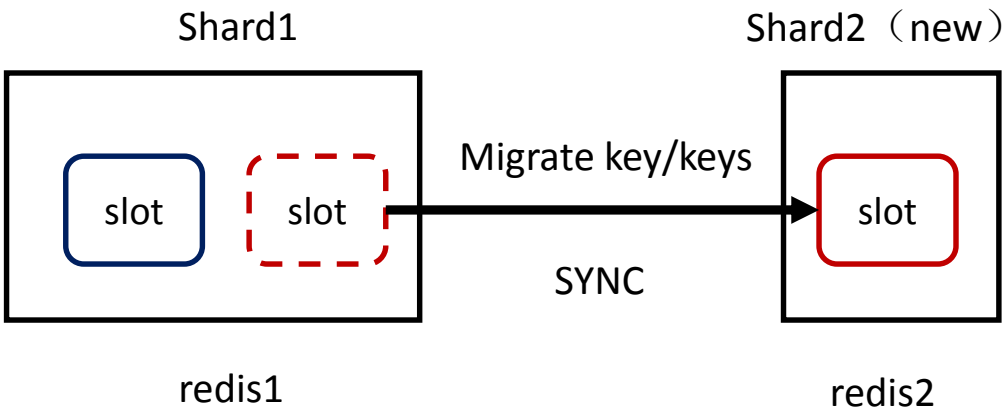

核心：数据迁移方案

- 迁移效率：单个key迁移效率低下（V3.2 keys）
- 迁移方式：同步迁移，迁移过程中影响服务读写

弹性扩缩容-BDRP方案

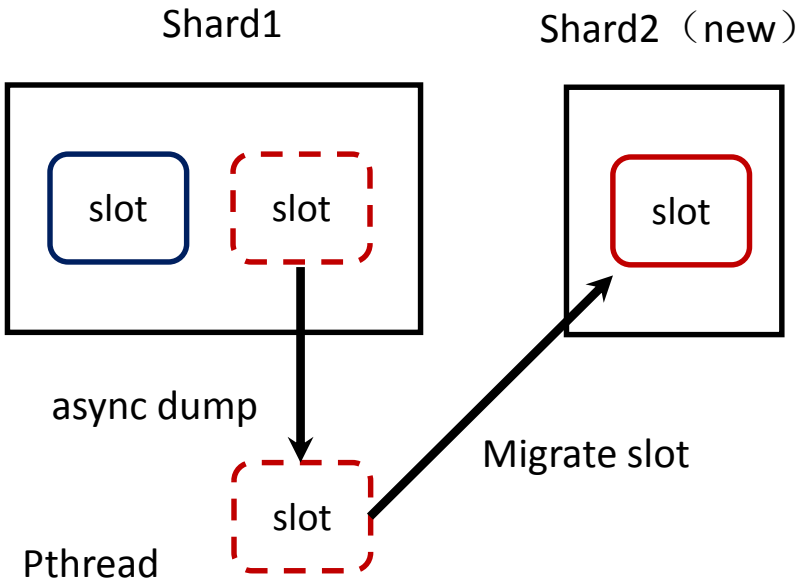

- 迁移效率：数据块整体聚合迁移，效率高
- 迁移方式：子线程异步dump和迁移数据，不影响读服务

基于服务混部的Auto Scaling

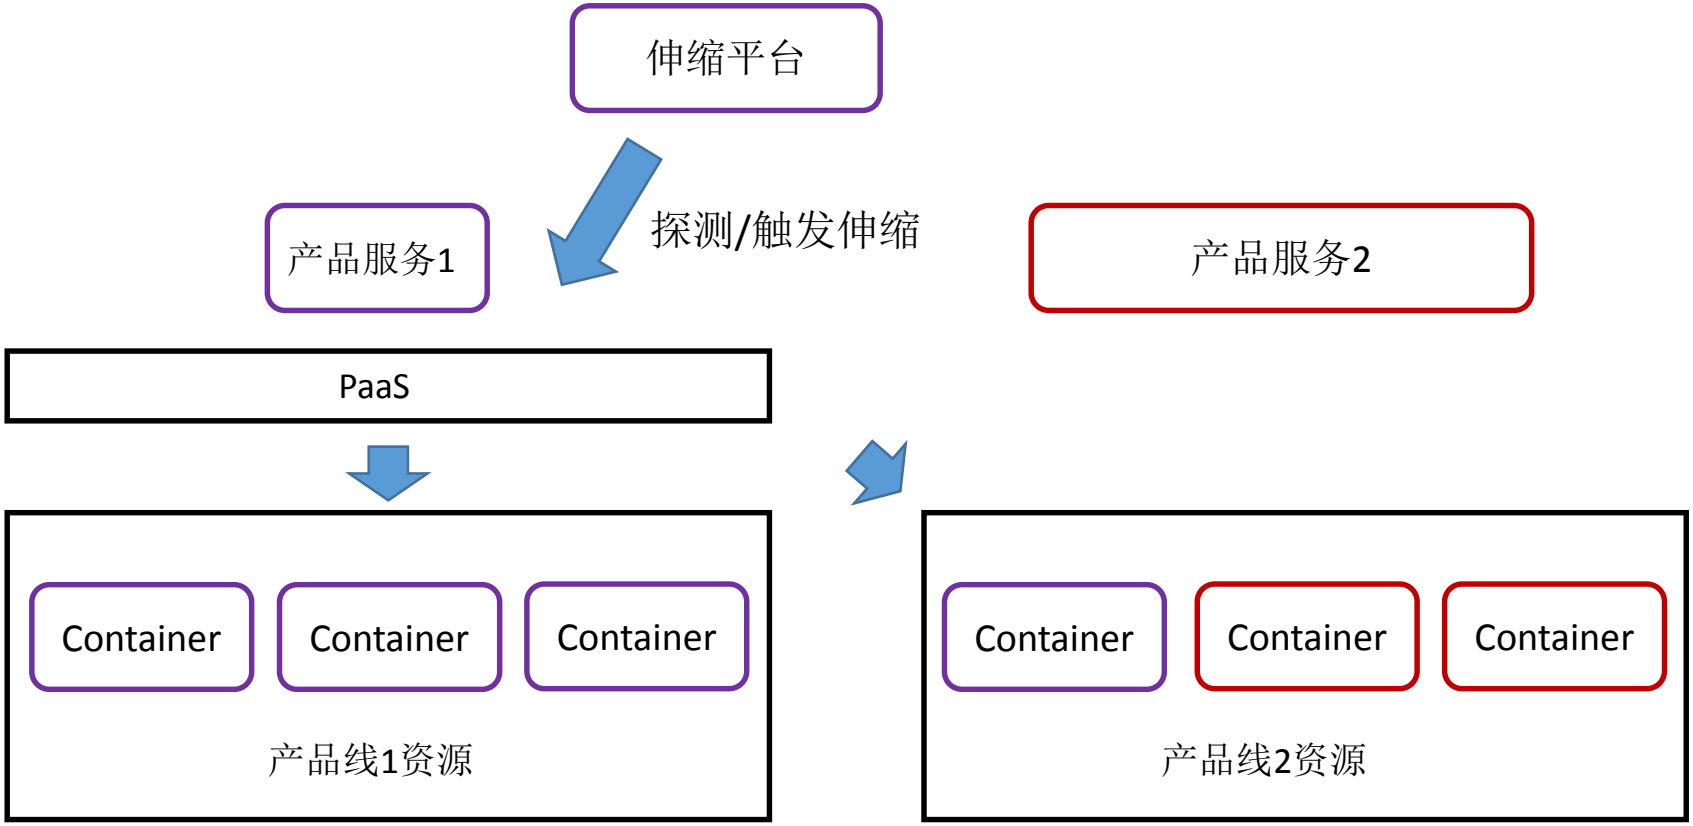

挑战-DB&CACHE使用

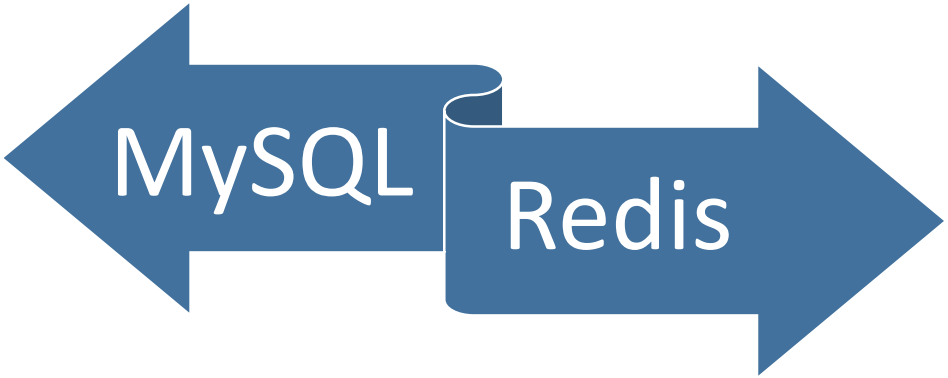

- Redis作为CACHE的场景下，业务无法判断MySQL和Redis的最佳配比
  - 资源
  - 性能
- 同时使用MySQL协议和Redis协议
- 维护MySQL和Redis数据一致性

DB&CACHE-已有方案

InnoDB with Memcached

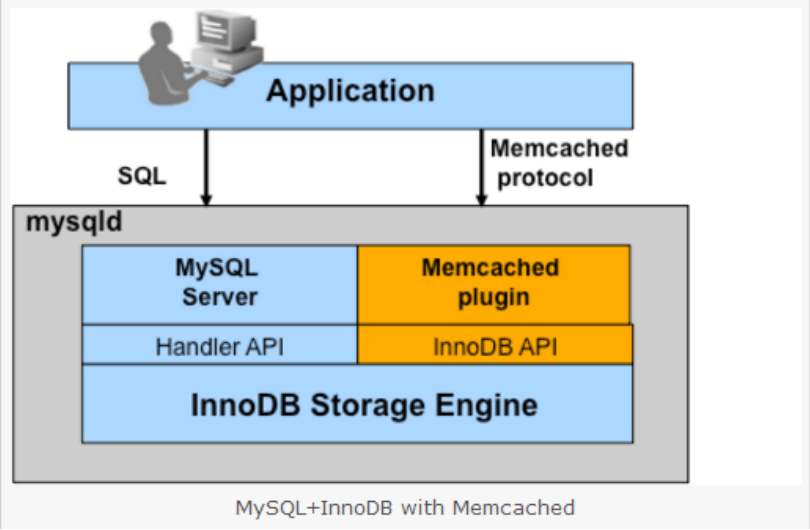

MySQL+InnoDB with Memcached

- 协议未统一
- 受限单机内存

MySQL Memcached UDFs

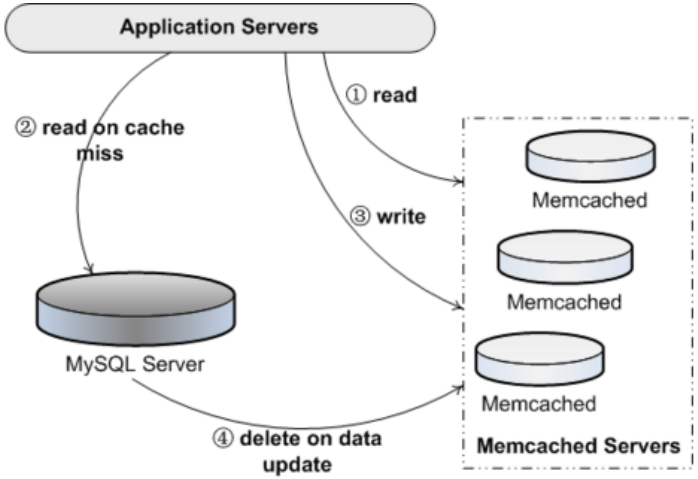

- 协议未统一
- 需要用户处理数据一致性

MySQL&Redis融合

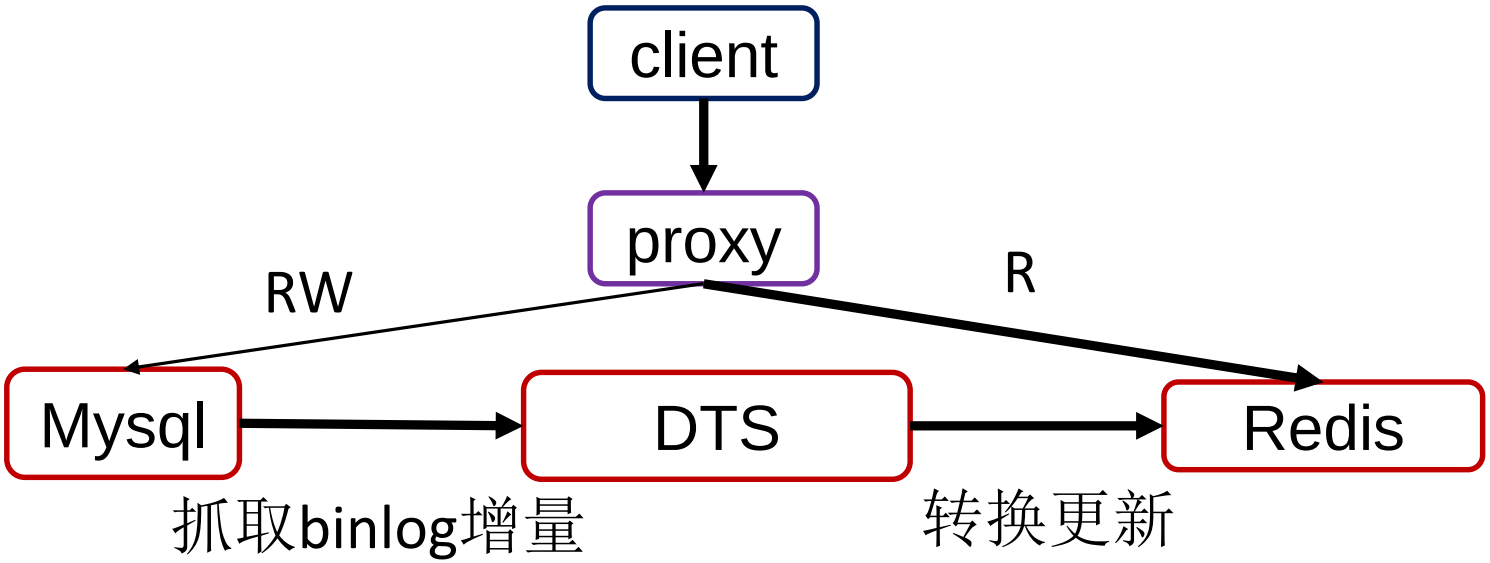

- Proxy：分发不同存储
- DTS:完成MySQL->redis数据同步
- 访问协议为MySQL协议

MySQL&Redis融合-数据转化

- 库名:DB
- 表名：TABLE
- 表主键：PRIMARY_KEY

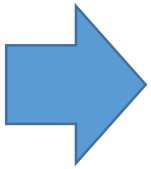

- key:DB.TABLE_11_PRIMARY_KEY
- value:PRIMARY_KEY

对应的组合内容

Mysql&Redis融合-查询逻辑

- Proxy自带SQL Parser
- 写入进入主库
- 非KV类查询进入从库
- KV类查询进入Redis
- 结果集为MySQL协议

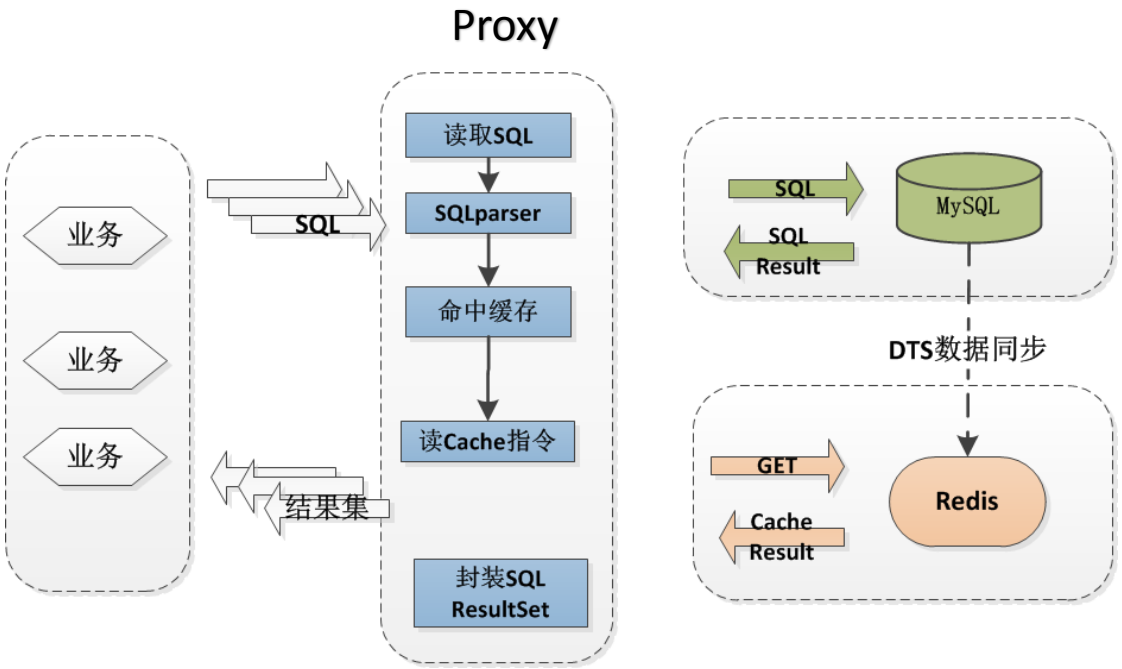

MySQL&Redis融合-一致性保证

- 填充方案
  - 全量CACHE： DTS
  - 热点填充： Proxy + DTS
- 同步监控
  - Redis延时过大摘除Redis

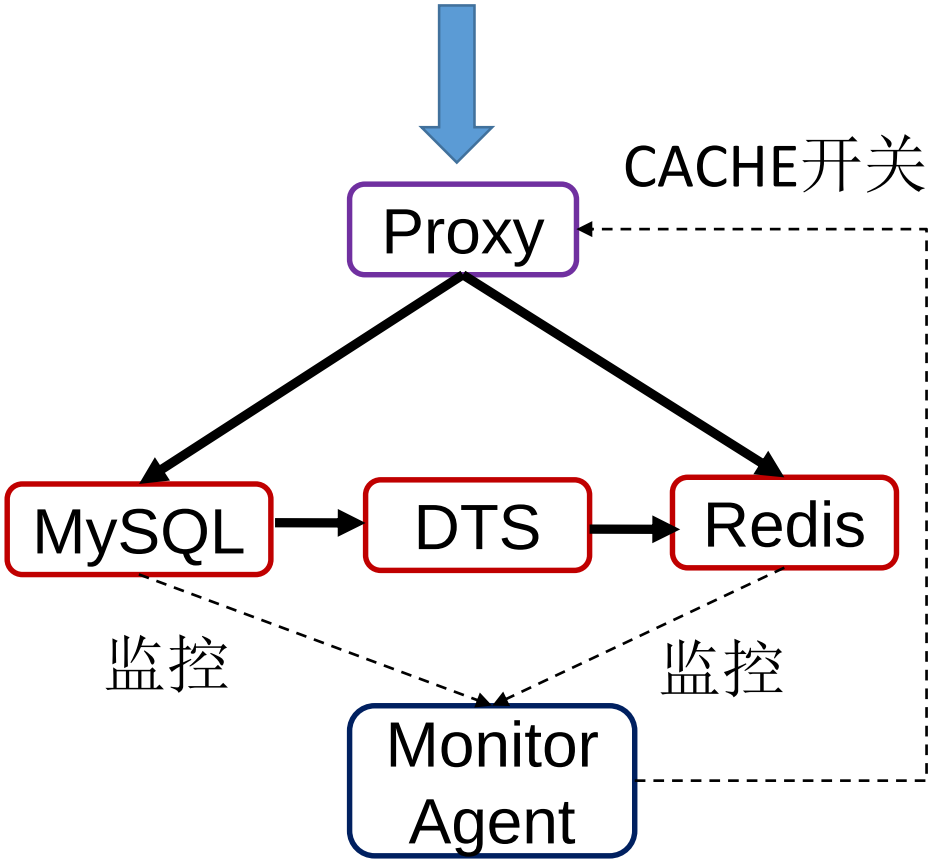

Mysql&Redis融合-指标和收益

- Redis更新时延ms级
- 可靠性(99.99%)
- 对比纯MySQL集群收益（Redis命中率90%）
  - 集群吞吐提升10倍
  - 长尾降低70%，平响降低20%
  - 业务无需任何改动

大纲

- BDRP在百度的应用
- 架构介绍
- 挑战与解决方案
- 总结

总结

- bdrp应用情况
- 架构
- 挑战与方案（糯米）
  - 近地域多机房解决方案
  - 1分钟整机房切主
  - 基于服务混部的Auto Scaling
  - MySQL&Redis融合方案

其他工作

- 远地域多机房服务
- 基于磁盘引擎的KV存储
- SCS&RDS融合方案
- 运维管理平台

百度DBA诚招天下英豪

- MySQL方向研发和运维
- Redis方向研发和运维

- 邮箱： dba@baidu.com
- 微信/QQ：174264744

THANKS

SequeMedia 盛拓传媒 IT168.com ChinaUnix ITPUB